基于 Give Me Some Credit 的信用评分卡分析

公开作品集版　s0Ap224 / credit-risk-scorecard

1　业务目标与样本划分

1.1　明确建模对象

本研究以 Kaggle 原始 Give Me Some Credit 竞赛中的匿名个人借款人信用记录为评分对象，在历史特征已可取得、未来表现尚未发生的评分时点 t_0，利用年龄、收入、负债、授信使用情况及历史逾期记录等信息，预测该借款人在随后两年内发生 90 天及以上严重逾期或更严重情形的概率。目标变量为 `SeriousDlqin2yrs`，取值 1 表示发生目标事件，取值 0 表示未发生，分别称为坏样本与好样本。评分用于风险排序、预警复核以及后续教学情景下的风险标记和模拟接受决策；模型概率越高，风险越高，转换后的评分卡则统一采用分数越高、风险越低的方向。

观察窗口、评分时点与表现窗口。　如图 1 所示，特征构造与结果观察以 t_0 为界：

1. **观察窗口：**汇总评分时点之前已形成且在 t_0 可获得的个人财务和信用历史，构造特征向量 $\boldsymbol{x}_i$（包含年龄、月收入、负债收入比等全部 10 个特征）。
2. **评分时点：**在 t_0 基于已有信息计算个体风险；行号仅用于追踪记录，不进入预测特征，未来表现信息（SeriousDlqin2yrs）不参与特征构造。
3. **表现窗口：**按照竞赛任务设定，在 t_0 后两年内观察是否发生目标事件，待窗口结束、标签成熟后评价预测结果。

令 Y_i 表示第 i 条记录对应借款人在两年表现窗口内的目标事件，则

$$Y_i = \begin{cases} 1, & \text{两年表现窗口内发生严重逾期或更严重情形,} \\ 0, & \text{该窗口内未发生上述目标事件,} \end{cases} \qquad p_i = P(Y_i = 1 \mid \boldsymbol{x}_i)\,. \quad (1)$$

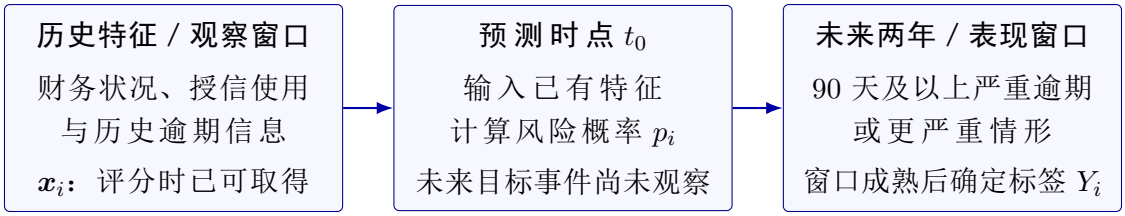


图 1: 历史特征、预测时点与表现窗口的关系（示意图不按时长比例绘制）

时间口径与应用范围。　上述两年表现窗口依据竞赛任务及本次作业设定。公开文件未提供逐户评分日期，无法据此还原各人的观察窗口起止日期；各历史变量的统计口径以数据字典为准。

1.2　固定样本划分

以 `SeriousDlqin2yrs` 为分层标签，固定随机种子为 20261103，将全部 150,000 条记录按 60%/20%/20% 划分。先分出 60% 的训练集，再将剩余 40% 等分为验证集和测试集；两次均使用同一随机种子并按标签分层。各子集规模与坏样本率见表 1。分层使各部分的事件比例接近总体的 6.684%。

表 1: 固定分层随机划分的样本构成（坏样本为正类）

子集	样本数	好样本数	坏样本数	坏样本率	样本占比
训练集	90,000	83,984	6,016	6.684%	60%
验证集	30,000	27,995	2,005	6.683%	20%
测试集	30,000	27,995	2,005	6.683%	20%
合计	150,000	139,974	10,026	6.684%	100%

重复与同源记录核查 原始行号唯一，但仅作为追踪键。排除行号后，按十个特征和标签检查完全重复记录，发现 609 条相对于各组首条的重复行；仅按十个特征（含缺失位置）匹配，有 354 组、共 1,000 条记录，其中 246 组分布在多个子集。因缺少客户主键（名称或者用户 id 等唯一编码信息）和逐户日期，无法确认这些记录是否来自同一借款人，故本次保留原始全部行，按指定比例进行记录层面的分层留出，即以每行为划分单位，在好、坏样本中分别按比例随机划分训练、验证和测试集，不要求同特征记录进入同一集合。

各部分用途 训练集用于估计清洗参数、分箱切点、档位合并规则、WOE、IV 以及模型系数；验证集用于比较和选择模型方案、概率校准方案与决策阈值；待数据处理规则、模型及阈值全部冻结后，测试集仅承担最终评价，不据其结果回调方案。若在训练集内部实施交叉验证，则每一折的分箱、WOE 编码、特征筛选及其他数据驱动处理均须仅在该折训练部分重新学习，折内验证部分只应用已学得的规则，避免信息泄漏。

2 数据预处理与探索性分析

2.1 数据审计

审计全体 150,000 条及固定训练集 90,000 条记录。表 2 为全样本非缺失有限值的线性插值分位数。行号、目标分别为标识与标签；十项特征均为数值型，家属人数虽存为浮点数，仍属计数。

表 2: 全样本特征审计摘要（比例变量保留原始比值）

变量	类型	缺失率	最小值	P25	中位数	P75	P99	最大值
额度使用率	比例	0.000%	0	0.03	0.154	0.559	1.093	50,708
年龄	年龄	0.000%	0	41	52	63	87	109
30–59 天逾期次数	计数	0.000%	0	0	0	0	4	98
负债收入比	比例	0.000%	0	0.175	0.367	0.868	4,979.04	329,664
月收入	金额	19.821%	0	3,400	5,400	8,249	25,000	3.009×10^6
在用信贷账户数	计数	0.000%	0	5	8	11	24	58
90 天及以上逾期次数	计数	0.000%	0	0	0	0	3	98
房地产贷款数	计数	0.000%	0	0	1	2	4	54
60–89 天逾期次数	计数	0.000%	0	0	0	0	2	98
家属人数	计数	2.616%	0	0	0	1	4	20

缺失集中于月收入（29,731 条）和家属人数（3,924 条），训练集分别为 17,840、2,355 条，其余特征无缺失。

另有零年龄 1 条（训练集 0 条）、零收入 1,634 条、逾期 96/98 特殊记录 269 条。额度使用率、负债收入比大于 1 的记录分别为 3,321、35,137 条。处理规则见第 2.3 节。

2.2 特征分布与风险关系

图 2 仅用固定训练集展示四变量的分布与坏样本率，缺失和特殊值单列。展示区间用于 EDA，不等同于最终评分卡分箱。

负债收入比 $(0.2, 0.4]$、$(0.6, 1]$ 及大于 100 组的坏样本率为 5.65%、10.28%、5.97%。尾部组 99.98% 伴随收入缺失、为零或低于 10，下降应结合人群构成与取值口径解释。

月收入 $[2{,}000, 4{,}000)$ 与至少 10,000 组为 9.22%、4.43%，与偿债缓冲的解释一致；零收入及 $(0, 10)$ 组为 3.67%、2.95%，需单独考察。缺失组 5.76% 低于非缺失组 6.91%。

家属人数 0 人与至少 4 人组为 5.83%、10.20%，与家庭负担的解释一致；缺失组 4.50% 低于非缺失组 6.74%。

60–89 天历史逾期 0、1、2 次及普通至少 3 次组为 5.12%、30.49%、48.31%、58.22%，梯度清楚。96/98 单列 161 人、56.52%，字典未解释其特殊含义。上述均为边际关联，不据此推断因果或缺失机制。

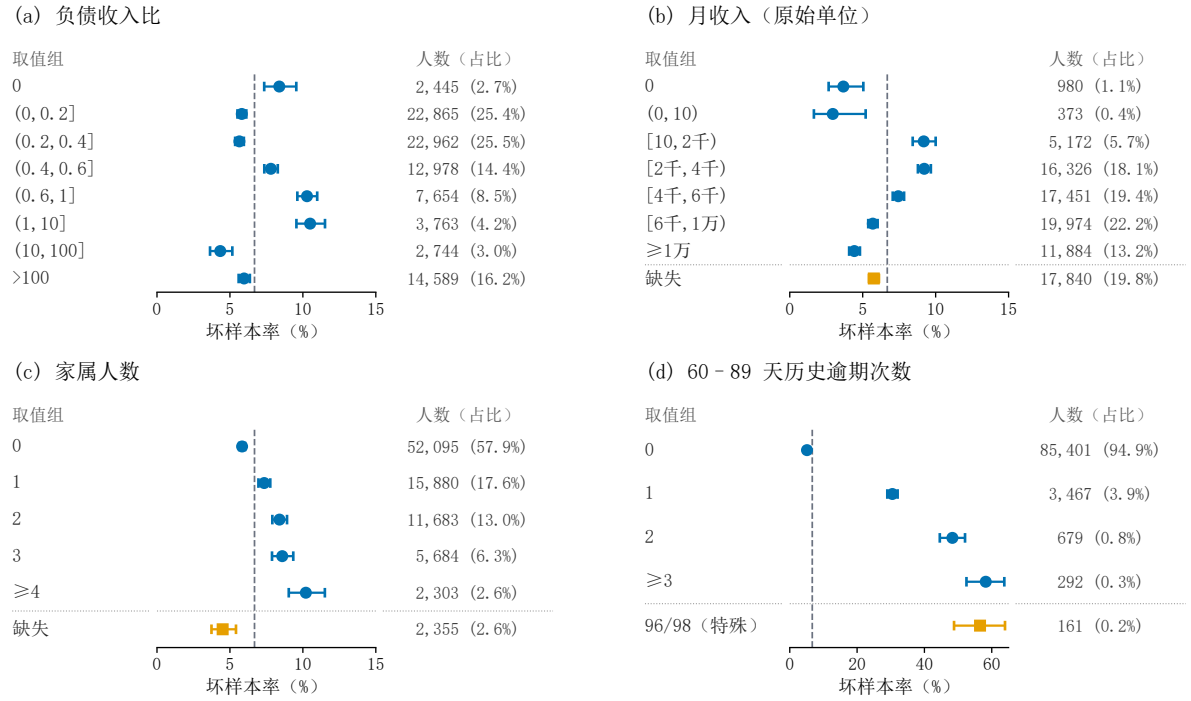


图 2: 四变量的训练集分布与边际风险

注：点为坏样本率，横线为记录层面的 Wilson 95% 二项比例区间，右列为人数及占全部训练样本的比例。虚线为训练集总体坏样本率，方块标记缺失或 96/98 特殊组；各面板横轴范围不同。

2.3 异常值和缺失值处理

按家属人数、逾期编码、收入状态依次处理，标记允许重叠，规则见表 3。相较于无标记的直接填补，保留指示或独立状态可避免混同图 2 中风险不同的人群；本节选定数据准备方案，预测性能仍由后续验证比较。

表 3: 缺失与特殊值的冻结处理规则

对象	处理及迁移规则
家属人数	原缺失先标记为 1 再补 0，原生零值标记为 0，保留两类差异。
三类逾期	保留原值，逐列标记 96/98 并合为该变量的特殊档；共同标记仅追踪任一列命中，避免重复计人数。
月收入	保留原值；缺失、$[0,10)$、$[10,+\infty)$ 分别为 `MISSING`、`LOW`、`REGULAR`。前两者路由特殊档，10 归普通档，原 NA 由缺失状态映射。
年龄	缺失或不大于 0 时补训练集有效年龄中位数 52 岁并标记。本次改动 1 条；训练中恒定的异常标记仅供审计，不估计系数。
比例与长尾	DebtRatio 在各收入状态下保留；比例大于 1、高收入及其他合法长尾均不截尾或删行，普通分箱和 WOE 留待模块三学习。

家属人数缺失的处理依据 在完整训练集中，家属人数缺失组的坏样本率为 4.50%，原生零值组为 5.83%，均低于家属人数为正组的 8.08%，呈现相对较低的边际风险。因此，选择 0 作为缺失记录的数值占位，同时保留原缺失指示，使其在数值表示上与零值组衔接，并允许后续模型识别缺失状态的附加信息。这一处理不将两组风险视为相同，也不认定缺失客户的真实家属人数为 0；相较于直接补 0，缺失标记保留了两类记录的区别。

逾期特殊编码的保留依据 三类逾期字段的 96/98 在训练集中命中同一批 161 条记录，其中 91 条为坏样本，坏样本率达 56.52%，明显高于训练集总体的 6.68%。该编码状态具有较强的样本风险区分信息，直接删除会丢失目标事件高度集中的记录。鉴于公开字典未明确其业务含义，本研究保留原始记录，将 96/98 合并为特殊档，既保留其风险信息，也避免将未知编码当作正常逾期次数排序。其中 96 仅有 2 条训练记录，与 98 合并可避免对极稀疏子组单独估计风险；三列共享的特殊状态在联合建模时仍需检查重复信息。

收入三种状态的划分依据 为考察非逾期特殊编码人群中的收入关系，在不含 96/98 的 89,839 条训练记录中比较：收入缺失、$[0,10)$ 及 $[10,+\infty)$ 三组分别有 17,768、1,347、70,724 条，坏样本率分别为 5.57%、3.34%、6.91%。缺失与极低收入组不仅区别于普通收入组，彼此也呈现不同的边际风险，因此分别设置 `MISSING` 和 `LOW` 状态，避免预先合并，普通收入组再于后续学习常规分箱。这是基于记录状态与风险分布的编码选择，并不意味着收入越低越安全。上述条件样本仅用于解释收入分层，实际转换仍覆盖所有记录，包括命中 96/98 的客户，收入状态与逾期标记可以重叠。

数据处理后，三个子集的样本个数不变。参数只从训练特征估计，冻结后统一用于验证、测试及新客户；交叉验证在折内重估。合法超训练范围值保留，由后续开口箱覆盖；缺字段、非法格式、无穷值、负收入或比例、负或非整数计数及未约定缺失均报字段级错误，不静默删行。新客户无需标签；完整规则清单、变动人数和标记重叠记录随代码保存。

3 分箱、WOE 与 IV

3.1 分箱方案

在第 2.3 节处理结果上，结合变量定义、训练集分布与已观察的风险关系，确定表 4 的初始分箱方案。连续变量采用便于解释的业务边界，离散计数保留低次数差异并合并稀疏尾部；缺失及未知特殊编码优先按既定规则路由。各变量独立分箱，同一客户可以

同时属于收入特殊档和某逾期字段的特殊档，保留全部记录。

表 4: 十个原始特征的初始分箱方案

特征	候选分箱	主要考虑
循环额度使用率	0；$(0, 0.1]$；$(0.1, 0.3]$；$(0.3, 0.6]$；$(0.6, 1]$；$(1, +\infty)$	零使用率单列；保留超额度状态。
年龄	$(0, 30)$；$[30, 40)$；$[40, 50)$；$[50, 60)$；$[60, 70)$；$[70, +\infty)$	按年龄段划分，考察风险随年龄的变化。
30–59 天逾期次数	0；1；2；3；普通值 ≥ 4；96/98 特殊档	区分首次与重复逾期，合并普通高次数尾部。
负债收入比	0；$(0, 0.4]$；$(0.4, 0.6]$；$(0.6, 1]$；$(1, 10]$；$(10, 100]$；$(100, +\infty)$	保留 1 的业务边界及非单调尾部。
月收入	缺失；$[0, 10)$；$[10, 4{,}000)$；$[4{,}000, 6{,}000)$；$[6{,}000, 10{,}000)$；$[10{,}000, +\infty)$	前两档为既定特殊状态，普通收入再分层。
开放信贷账户数	0；1–2；3–5；6–9；10–14；≥ 15	兼顾信贷经历不足与账户较多的不同含义。
90 天及以上逾期次数	0；1；2；普通值 ≥ 3；96/98 特殊档	保留严重逾期次数的风险梯度。
房地产贷款或额度数	0；1–2；3；≥ 4	区分无此类贷款、少量持有及较多持有。
60–89 天逾期次数	0；1；普通值 ≥ 2；96/98 特殊档	普通 ≥ 3 次仅 292 人，先与 2 次合并。
家属人数	0；1；2；3；≥ 4	基于填补后数值分箱，另保留原缺失指示。

分箱约束与标记用途 普通箱以训练样本数不少于 450（训练集的 0.5%）、好坏样本各不少于 30 作为初步检查标准，结合相邻风险差异与业务含义决定是否合并。具有明确识别规则的特殊档（例如借款人的三类逾期 96/98 编码）可保留较小样本规模。家属人数的零值箱包含原生零值及缺失后补零的记录，同时将 `NumberOfDependents_missing` 的 0/1 两档作为候选输入，保留缺失信息。

DebtRatio 尾部分档的依据 字典将 DebtRatio 定义为每月债务偿付、赡养费和生活费用与月总收入之比。因此，大于 1 表示这些支出超过当月收入，提示负担较重、需要进一步核查，不能仅据此判为错误。表 4 中大于 1 的各档仍为普通数值档，与未知编码的特殊档含义不同。图 2 显示，坏样本率由 $(0.2, 0.4]$ 档的 5.65% 上升至 $(0.4, 0.6]$、$(0.6, 1]$ 和 $(1, 10]$ 档的 7.81%、10.28% 和 10.50%，随后在 $(10, 100]$ 和大于 100 档降至 4.34% 和 5.97%。两个尾部档分别有 2,744 和 14,589 人，不能将其下降简单归为极少数记录造成的波动。

交叉统计进一步发现，大于 100 的 14,589 人中，收入缺失、为零和大于零但低于 10 的人数分别为 13,586、724 和 276，三组合计 14,586 人，占 99.98%；相应坏样本率分别为 6.14%、4.01% 和 2.90%。DebtRatio 大于 1 后，各区间的坏样本率差异明显，且未呈现单调变化；极高值又集中于收入缺失或极低的样本，不能简单理解为比率越大、风险越高。因此，保留这些区间分别分箱，避免强行合并掩盖风险差异，后续再结合收入状态和验证集表现决定是否调整。

3.2 WOE 与 IV 编码

以固定训练集的 $N_0 = 83{,}984$ 个好样本和 $N_1 = 6{,}016$ 个坏样本计算编码。对某变量的第 k 档，记好、坏样本数为 n_{0k}、n_{1k}，总档数为 K，其中缺失、低收入及 96/98 等已定义的特殊档均计入 K。两类样本在各档的平滑分布为：

$$g_k = \frac{n_{0k} + \alpha}{N_0 + \alpha K}, \qquad b_k = \frac{n_{1k} + \alpha}{N_1 + \alpha K}, \qquad \alpha = 0.5. \tag{2}$$

WOE 统一采用好样本分布除以坏样本分布：

$$\mathrm{WOE}_k = \ln \frac{g_k}{b_k}. \tag{3}$$

因此，正 WOE 表示该档相对更多地聚集好样本，负 WOE 表示相对更多地聚集坏样本。逐档 IV 贡献及变量总 IV 定义为

$$\mathrm{IV}_k = (g_k - b_k) \ln \frac{g_k}{b_k}, \qquad \mathrm{IV} = \sum_{k=1}^{K} \mathrm{IV}_k. \tag{4}$$

本报告选择列出 `DebtRatio` 和 `NumberOfTimes90DaysLate` 的分箱结果, 详见表 5、表 6 ；其余变量的全表保存在配套 CSV 中。第 3.1 节方案执行后，各变量档数与该节初始设计一致，本轮未再次合并。全部普通档人数至少为 779，好、坏样本数分别至少为 287、106，均通过预定要求。96/98 档共 161 人，作为未知编码的特殊状态独立保留。

表 5: DebtRatio 的完整训练分箱表

档位	人数	好	坏	坏率	g_k	b_k	WOE	IV 贡献
0	2,445	2,240	205	8.38%	0.02668	0.03414	-0.2467	0.00184
$(0, 0.4]$	45,827	43,201	2,626	5.73%	0.51438	0.43633	0.1646	0.01284
$(0.4, 0.6]$	12,978	11,965	1,013	7.81%	0.14247	0.16837	-0.1670	0.00433
$(0.6, 1]$	7,654	6,867	787	10.28%	0.08177	0.13082	-0.4700	0.02306
$(1, 10]$	3,763	3,368	395	10.50%	0.04011	0.06570	-0.4936	0.01263
$(10, 100]$	2,744	2,625	119	4.34%	0.03126	0.01985	0.4540	0.00518
$(100, +\infty)$	14,589	13,718	871	5.97%	0.16334	0.14478	0.1206	0.00224
合计	90,000	83,984	6,016	6.68%	1	1	—	0.06212

表 6: NumberOfTimes90DaysLate 的完整训练分箱表

档位	人数	好	坏	坏率	g_k	b_k	WOE	IV 贡献
0	84,989	81,057	3,932	4.63%	0.96513	0.65340	0.3901	0.12159
1	3,159	2,094	1,065	33.71%	0.02494	0.17704	-1.9599	0.29811
2	912	476	436	47.81%	0.00567	0.07253	-2.5481	0.17035
≥ 3	779	287	492	63.16%	0.00342	0.08183	-3.1741	0.24887
96/98（特殊）	161	70	91	56.52%	0.00084	0.01520	-2.8965	0.04161
合计	90,000	83,984	6,016	6.68%	1	1	—	0.88053

一档独立核算　DebtRatio 的 $(1, 10]$ 档有 3,368 个好样本、395 个坏样本，变量共 $K = 7$ 档。将人数直接代入式 (2)–(4)：

$$\begin{aligned} g_k &= \frac{3{,}368 + 0.5}{83{,}984 + 0.5 \times 7} = 0.0401072, \qquad b_k = \frac{395 + 0.5}{6{,}016 + 0.5 \times 7} = 0.0657031, \\ \mathrm{WOE}_k &= \ln\left(\frac{0.0401072}{0.0657031}\right) \approx -0.4936, \qquad \mathrm{IV}_k \approx 0.01263. \end{aligned} \tag{5}$$

该档占全部坏样本的比例高于其占全部好样本的比例，因而 WOE 为负；其档内坏样本率 10.50% 也高于训练集总体的 6.68%。图 3 展示各档编码：严重逾期的普通档随次数增加而 WOE 下降，DebtRatio 则保留前文解释的非单调关系，96/98 不参与普通次数的排序。

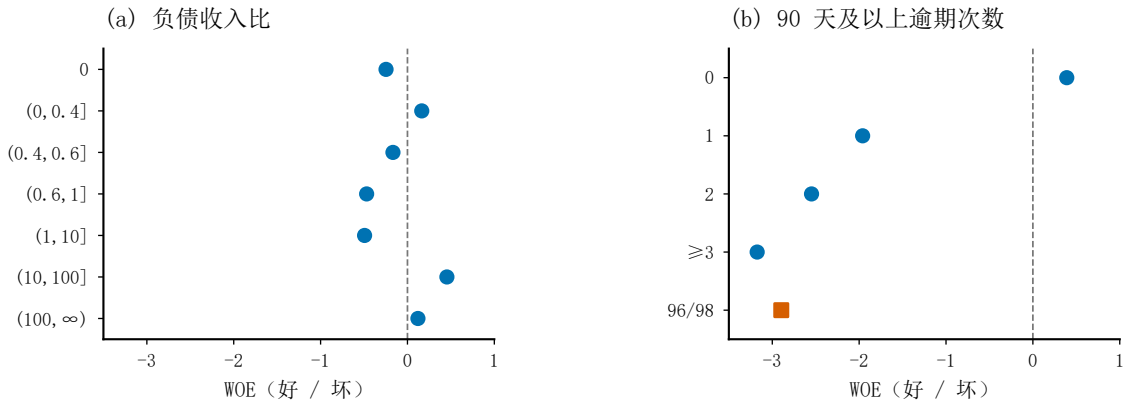


图 3: DebtRatio 与历史严重逾期的 WOE 分布

注：点为训练集平滑 WOE，圆点为普通档，方块为 96/98 特殊档，虚线表示 WOE 为 0。

编码冻结与迁移　保存切点、开闭端点、特殊路由和训练 WOE，验证客户按同一规则查表，后续测试及新客户也使用该映射，不根据其标签重新计算编码。若在训练集内部进行交叉验证，数据驱动的切点设计、预处理、WOE 和变量选择均须在各训练折内重做。

3.3　候选变量的选择

候选输入包括十个原始变量和家属人数原缺失指示，共 11 项。表 7 按训练 IV 排序。IV 衡量单个变量在当前分箱下的边际区分能力，不代表进入联合模型后的独立贡献，也不要求风险关系单调。故以 IV 确定检查优先级，再结合字段时点、档量、冗余与验证表现作取舍。

高 IV 的来源与字段时点　对于额度使用率和三类逾期的 IV 均超过 0.5 的候选变量，需要核查其区分信息是否依赖稀疏档或未来信息。额度使用率的最小档有 1,973 人；三类逾期普通档最少分别有 805、971、779 人（依次为 30–59、60–89、90 天及以上），并无零好样本或零坏样本档。96/98 对三类逾期总 IV 的贡献占比分别仅为 5.3%、7.1%、4.7%，说明高 IV 主要来自普通逾期记录的分布差异，不能归因于这 161 人的特殊编码。因此，额度使用率和三类历史逾期变量均保留为候选变量。

表 7: 候选变量的训练集 IV 与初选结果

候选变量	档数	最小档人数	IV	特殊档 IV 占比	初选
额度使用率	6	1,973	1.1293	—	保留
90 天及以上逾期次数	5	161	0.8805	4.7%	保留
30–59 天逾期次数	6	161	0.7805	5.3%	保留
60–89 天逾期次数	4	161	0.5832	7.1%	保留
年龄	6	5,248	0.2513	—	保留
在用信贷账户数	6	1,119	0.1016	—	暂不纳入
月收入	6	1,353	0.0730	13.5%	暂不纳入
负债收入比	7	2,445	0.0621	—	保留
房地产贷款数	4	2,179	0.0589	—	保留
家属人数	5	2,303	0.0364	—	保留
家属人数原缺失指示	2	2,355	0.0038	—	暂不纳入

注：最小档人数包含特殊档；特殊档 IV 占比为其贡献之和除以变量总 IV。三类逾期的特殊档均为 96/98，月收入的特殊档为缺失及 $[0, 10)$。初选结果同时使用表 8 的联合诊断，不按 IV 阈值直接删除。

候选变量方案确定 为判断候选变量在联合模型中是否仍提供额外信息，使用相同设置的 Logistic 模型比较不同变量组合，结果见表 8。完整 11 项方案作为参照，比较按 IV 阈值筛选及综合筛选后的验证表现。

表 8: 候选变量方案的验证集诊断表现

诊断方案	变量数	AUC	KS	对数损失	Brier
全部 11 项	11	0.8639	0.5692	0.18130	0.04997
仅 IV ≥ 0.02	10	0.8639	0.5690	0.18129	0.04996
仅 IV ≥ 0.10	6	0.8598	0.5666	0.18245	0.05012
综合初选方案	8	0.8636	0.5678	0.18138	0.04997

8 项初选方案的形成过程 完整模型先纳入全部 11 项，然后依训练 IV 由小到大逐项试删，每次删除后重新拟合模型并计算验证指标。候选变量简化统一基准：AUC 最多减少 0.001，对数损失和 Brier 最多各增加 0.0001，三项同时满足才简化；KS 用作辅助观察。这些差异界限是本研究预设的简化标准，不是统计显著性检验。实际通过检查的三次删除见表 9，其间其他变量的试删未通过，故继续保留。

表 9: 从 11 项到 8 项的已接受删选步骤

当前组合	项数	AUC	KS	对数损失	Brier
完整方案	11	0.863872	0.569176	0.181303	0.049968
去掉家属人数缺失指示	10	0.863898	0.568997	0.181289	0.049961
再去掉月收入	9	0.863562	0.567191	0.181372	0.049967
再去掉在用信贷账户数	8	0.863584	0.567834	0.181375	0.049965

家属人数原缺失指示的 IV 为 0.0038，单独区分能力较弱；从完整模型中去掉它后，符合上文提到的简化条件。

月收入的 IV 为 0.0730，尽管其具有一定的单变量信息，但数据发现，在去掉家属人数缺失指示的基础上，再去掉月收入，AUC 从 0.863898 降至 0.863562，对数损失从

0.181289 升至 0.181372，但相对完整方案的差异仍在上述界限内。另一方面，本数据中该字段的信息完整性有限：训练集约 19.82% 的收入缺失，另有约 1.50% 的收入低于 10，两类合计约占 21.33%。这些记录虽已通过特殊分箱保留状态信息，却难以直接解释为客户的正常收入水平。

在用信贷账户数的 IV 为 0.1016，但在上述 9 项组合中去掉它，符合上文提到的简化条件，当前联合预测中仍可省略。三个变量的取舍均依据实际试删结果，而非达到或未达到某个 IV 阈值。

由此，进入模块四的 8 项候选为额度使用率、年龄、三类历史逾期次数、DebtRatio、房地产贷款数和家属人数。该组合以较少输入取得接近完整方案的验证表现，是本次顺序筛选的初选结果；最终效果仍在模型冻结后通过测试集评价。

4 Logistic 建模与比较基准

4.1 模型估计与诊断

将第 3.3 节的 8 项冻结 WOE 输入模型，以坏样本为正类：

$$Y_i \mid \boldsymbol{x}_i \sim \text{Bernoulli}(p_i), \qquad \eta_i = \log\frac{p_i}{1-p_i} = \beta_0 + \sum_{j=1}^{8} \beta_j w_j(x_{ij}). \tag{6}$$

概率为 $p_i = (1+e^{-\eta_i})^{-1}$。按记录采用条件独立的工作假设，重复与同源限制沿用第 1.2 节；条件对数几率对 WOE 加性，无需八个特征相互独立。固定 $C = 1$，以无类别权重的 L2 惩罚估计

$$\widehat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \left\{ \sum_{i \in \mathcal{T}} \left[\log(1 + e^{\eta_i}) - Y_i \eta_i \right] + \frac{1}{2C} \sum_{j=1}^{8} \beta_j^2 \right\}, \tag{7}$$

其中 $\mathcal{T}$ 为训练集，截距不惩罚。采用 `lbfgs` 数值优化算法、容差 10^{-8}、最多 2,000 次迭代，在 30 次后收敛。含截距的标准化诊断矩阵秩为 9、条件数为 1.83，最大 VIF 为 1.25。后可根据此惩罚估计得到八个候选变量的 WOE Logistic 的估计系数。

表 10: 八变量 WOE Logistic 的估计系数

项	系数 $\widehat{\beta}$	$\exp(\widehat{\beta})$
截距	-2.60255	0.0741
额度使用率	-0.61583	0.5402
年龄	-0.40832	0.6648
30–59 天逾期次数	-0.51178	0.5994
负债收入比	-0.76611	0.4648
90 天及以上逾期次数	-0.53753	0.5842
房地产贷款数	-0.67415	0.5096
60–89 天逾期次数	-0.35875	0.6986
家属人数	-0.28302	0.7535

注：非截距行的指数表示其他 WOE 固定时，该变量增加 1 个 WOE 单位的坏样本几率比；截距项的指数表示所有 WOE 为 0 时的坏/好几率。

表 10 八项系数均为负：WOE 增大时条件坏样本几率下降。以负债收入比为例，当其他七项 WOE 不变时，负债收入比的 WOE 增加 1 个单位，坏样本几率变为原来的 0.5402 倍，即降低约 45.98%。年龄系数的单位也是 WOE，并非每增加一岁的效应，截距不代表平均客户风险。

4.2 具体档位的条件几率比

同一变量由档位 a 变为 b，其余七项输入固定时，

$$\mathrm{OR}_{b:a} = \frac{p_b/(1-p_b)}{p_a/(1-p_a)} = \exp\Big\{\widehat{\beta}_j\big(w_{j,b} - w_{j,a}\big)\Big\}. \tag{8}$$

以第 5 节的低风险人工输入为参照。负债收入比分别设为 0.25 与 2，严重逾期次数分别设为 0 与 1。分别只改设负债比或严重逾期档位，结果见表 11。DebtRatio 的 WOE 差为 -0.65815，与系数 -0.76611 结合得到 OR ≈ 1.656；严重逾期的 WOE 差为 -2.35001，与系数 -0.53753 结合得到 OR ≈ 3.537。几率倍数不等于概率倍数；概率变化依赖参照特征，表示模型情景比较，不解释为因果效应。

表 11: 固定其余特征后的档位比较

变量	档位变化 $a \to b$	条件几率比	p_a	p_b
负债收入比	$(0, 0.4] \to (1, 10]$	1.656	1.13%	1.85%
90 天及以上逾期次数	$0 \to 1$	3.537	1.13%	3.88%

4.3 两个基准与同样本比较

常数概率基准 对所有客户预测训练集坏样本率 $\widehat{p}_0 = 6{,}016/90{,}000 = 6.6844\%$，不从测试标签重估先验。

原始字段 Logistic 基准 同样八个字段中，年龄保留原值，其余取 $\log(1+x)$。96/98 对应普通计数置 0，以单个“任一逾期特殊”指示保留状态，共 9 个设计量，避免三个相同标记重复输入。按训练均值和总体标准差缩放后冻结，使用同一 C、求解器及无权重设置，17 次后收敛，矩阵满列秩且未检出分离。

两模型参数和规则先冻结，随后才打开同一批 30,000 条测试记录（坏样本 2,005 条），结果见表 15。两个 Logistic 模型采用相同的八个原始字段，分别使用数值变换后的原值表示和分箱后的 WOE 表示。测试结果显示，WOE 流程的 AUC 提高约 0.0235，KS 和 AP 同时提高，对数损失与 Brier 分别降低约 4.53% 和 2.91%，表明该流程在本次实验中改善了风险排序与整体概率预测质量。这与分箱能够表达不同取值区间的风险差异相一致，例如 DebtRatio 的非单调关系难以通过单一对数变换充分表达。

不平衡与准确率 训练沿用约 $13.96:1$ 的好坏比，各记录等权。给定模型预测的坏样本概率 $\widehat{p}_i$，记分类阈值为 t，由此定义预测标签

$$\widehat{Y}_i(t) = \begin{cases} 1, \text{ 标记为高风险客户}, & \widehat{p}_i \geq t, \\ 0, \text{ 不标记为高风险客户}, & \widehat{p}_i < t. \end{cases}$$

若误报与漏报代价相同且预测概率可信，标记和不标记的期望成本分别与 $1-\widehat{p}_i$ 和 $\widehat{p}_i$ 成正比。当 $1-\widehat{p}_i \leq \widehat{p}_i$ 时选择标记，得到等代价对照阈值 $t_0 = 0.5$。（即此时考虑误报好客户成本与漏报坏客户成本相同）

以坏样本为正类，将 WOE 模型的 $\widehat{Y}_i(t_0)$ 与测试集实际标签逐一比较，得到正确检出 $TP = 364$、漏报 $FN = 1{,}641$、误报 $FP = 244$、正确识别好客户 $TN = 27{,}751$。准

确率与坏样本召回率的定义及代入结果分别为

$$\mathrm{Accuracy}(t)=\frac{TP(t)+TN(t)}{N},\qquad \mathrm{Recall}_{\mathrm{bad}}(t)=\frac{TP(t)}{TP(t)+FN(t)},$$
$$\mathrm{Accuracy}(t_0)=\frac{364+27{,}751}{30{,}000}=93.72\%,\qquad \mathrm{Recall}_{\mathrm{bad}}(t_0)=\frac{364}{2{,}005}=18.15\%.$$

在该阈值下，好样本识别率为 99.13%。常数基准的预测概率低于 t_0，因而将所有人判为好样本，准确率等于好样本占比 93.32%，坏样本召回率为 0。好样本数量占优，使总体准确率主要反映多数类的识别表现。

5 评分刻度与标准评分卡

5.1 刻度推导与分数分解

设坏样本概率为 $p\in(0,1)$，好坏几率为 $O=\frac{1-p}{p}$，评分函数为 $S=A+B\ln O$。几率翻倍时分差为 $B[\ln(2O)-\ln O]=20$，且 $A+B\ln 19=600$，得到

$$B\ln 2=20,\qquad B=\frac{20}{\ln 2}\approx 28.853901,\qquad A=600-B\ln 19\approx 515.041450. \tag{9}$$

概率与分数之间的转换为

$$S(p)=A+B\ln\frac{1-p}{p},\qquad p(S)=\frac{1}{1+\exp\left(\frac{S-A}{B}\right)}. \tag{10}$$

令 $\widehat{\eta}_i$ 为式 (6) 的拟合对数几率。代入后可分解客户 i 的总分

$$S_i=A-B\widehat{\eta}_i=S_0+\sum_{j=1}^{8}s_j(x_{ij}),\qquad S_0=A-B\widehat{\beta}_0,\qquad s_j(x_{ij})=-B\widehat{\beta}_j w_j(x_{ij}). \tag{11}$$

评分锚点由 $O=19$ 给定，即 $p=\frac{1}{20}=5\%$ 时 $S=600$。令八项 WOE 均为零，则截距取值 b 对应基准概率 $p_0(b)=(1+\exp(-b))^{-1}$ 和基准分 $S_0(b)=A-Bb$，因此

$$b=0\quad\Longrightarrow\quad p_0(0)=50\%,\qquad S_0(0)=A\approx 515.041450,$$
$$\widehat{\beta}_0\approx -2.602547\quad\Longrightarrow\quad p_0(\widehat{\beta}_0)\approx 6.8975\%,\qquad S_0(\widehat{\beta}_0)\approx 590.135076.$$

由于 $\widehat{\eta}_i$ 随坏样本概率严格递增，$B>0$ 时坏样本概率越高，分数越低。对同一模型采用新刻度 $S_i'=A'-B'\widehat{\eta}_i$（$B'>0$），任意两位客户 i,k 满足

$$S_i'-S_k'=-B'(\widehat{\eta}_i-\widehat{\eta}_k)=\frac{B'}{B}(S_i-S_k).$$

截距 A' 在分差中抵消，B'/B 为正，分差的正、负和零均保持，因此未取整分数的先后与并列关系均保持。

5.2 完整评分卡

表 12 包含全部 43 档及独立基准分。整数展示对基准分和八项档分各取最近整数，恰好半分时远离 0，再相加；它不一定等于总分最后一次取整。计算及阈值评价均使用未取整分数，不截断分值。表中分值未取整，仅显示三位小数，完整精度另存 `scorecard.csv`。

表 12: 完整评分卡

档位	WOE	系数	分值	整数
截距基准分				
基准分	—	-2.60255	590.135	590
额度使用率				
0	0.73329	-0.61583	13.030	13
$(0, 0.1]$	1.52938	-0.61583	27.176	27
$(0.1, 0.3]$	0.80012	-0.61583	14.217	14
$(0.3, 0.6]$	-0.00187	-0.61583	-0.033	0
$(0.6, 1]$	-1.01802	-0.61583	-18.089	-18
$(1, +\infty)$	-2.08854	-0.61583	-37.112	-37
年龄				
$(0, 30)$	-0.61527	-0.40832	-7.249	-7
$[30, 40)$	-0.44917	-0.40832	-5.292	-5
$[40, 50)$	-0.25234	-0.40832	-2.973	-3
$[50, 60)$	0.02838	-0.40832	0.334	0
$[60, 70)$	0.69053	-0.40832	8.136	8
$[70, +\infty)$	1.09995	-0.40832	12.959	13
30-59 天逾期次数				
0	0.55345	-0.51178	8.173	8
1	-0.89868	-0.51178	-13.271	-13
2	-1.62457	-0.51178	-23.990	-24
3	-2.04305	-0.51178	-30.170	-30
≥ 4	-2.42905	-0.51178	-35.870	-36
96/98（特殊）	-2.89647	-0.51178	-42.772	-43
房地产贷款数				
0	-0.22430	-0.67415	-4.363	-4
1–2	0.22561	-0.67415	4.388	4
3	-0.04521	-0.67415	-0.879	-1
≥ 4	-0.62112	-0.67415	-12.082	-12
负债收入比				
0	-0.24666	-0.76611	-5.452	-5
$(0, 0.4]$	0.16456	-0.76611	3.638	4
$(0.4, 0.6]$	-0.16705	-0.76611	-3.693	-4
$(0.6, 1]$	-0.46997	-0.76611	-10.389	-10
$(1, 10]$	-0.49359	-0.76611	-10.911	-11
$(10, 100]$	0.45405	-0.76611	10.037	10
$(100, +\infty)$	0.12062	-0.76611	2.666	3
90 天及以上逾期次数				
0	0.39007	-0.53753	6.050	6
1	-1.95995	-0.53753	-30.398	-30
2	-2.54814	-0.53753	-39.521	-40
≥ 3	-3.17409	-0.53753	-49.230	-49
96/98（特殊）	-2.89654	-0.53753	-44.925	-45
60-89 天逾期次数				
0	0.28407	-0.35875	2.940	3
1	-1.81197	-0.35875	-18.756	-19
≥ 2	-2.68735	-0.35875	-27.817	-28
96/98（特殊）	-2.89662	-0.35875	-29.984	-30
家属人数				
0	0.15601	-0.28302	1.274	1
1	-0.10192	-0.28302	-0.832	-1
2	-0.24667	-0.28302	-2.014	-2
3	-0.27142	-0.28302	-2.216	-2
≥ 4	-0.46295	-0.28302	-3.781	-4

5.3 新客户评分函数与人工案例

设 $\boldsymbol{x} \in \mathcal{X}$ 为新客户的十项原始输入。用 T 表示第 2.3 节的冻结预处理和八项入模变量选取，令 $\widetilde{x}_j = [T(\boldsymbol{x})]_j$，$w_j(\widetilde{x}_j)$ 为按冻结档位查得的 WOE。新客户的坏样本概率和未取整总分由下式给出。

$$
\begin{aligned}
\widehat{\eta}(\boldsymbol{x}) &= \widehat{\beta}_0 + \sum_{j=1}^{8} \widehat{\beta}_j w_j(\widetilde{x}_j), \\
\widehat{p}(\boldsymbol{x}) &= \frac{1}{1 + \exp[-\widehat{\eta}(\boldsymbol{x})]}, \\
S(\boldsymbol{x}) &= A - B\widehat{\eta}(\boldsymbol{x}) = S_0 + \sum_{j=1}^{8} \bigl[-B\widehat{\beta}_j w_j(\widetilde{x}_j)\bigr].
\end{aligned}
\tag{12}
$$

式中系数、分箱、WOE 和刻度均取已冻结的值。函数 `score_customer` 接受包含十项原始字段的字典，返回 $\widehat{p}(\boldsymbol{x})$、$S(\boldsymbol{x})$、整数展示分及逐项明细。

构造低、中、高三组人工输入，使用同一冻结评分卡计算。风险标签表示三个案例的相对预测风险。表 13 展示八个入模特征的原值、档位、WOE 和档分，另两项输入与完整计算结果见仓库的 `examples/scenarios/`。总分另加基准分 S_0。

表 13: 三组人工输入的逐项评分

	低风险			中风险			高风险		
变量	原值 档位	WOE	档分	原值 档位	WOE	档分	原值 档位	WOE	档分
额度使用率	0.08 $(0, 0.1]$ 58	1.52938	27.176	0.35 $(0.3, 0.6]$ 35	−0.00187	−0.033	0.92 $(0.6, 1]$ 38	−1.01802	−18.089
年龄	$[50, 60)$ 0	0.02838	0.334	$[30, 40)$ 1	−0.44917	−5.292	$[30, 40)$ 2	−0.44917	−5.292
30–59 天逾期	0 0.25	0.55345	8.173	1 0.3	−0.89868	−13.271	2 0.57	−1.62457	−23.990
负债收入比	$(0, 0.4]$ 0	0.16456	3.638	$(0, 0.4]$ 0	0.16456	3.638	$(0.4, 0.6]$ 2	−0.16705	−3.693
90 天及以上逾期	0 1	0.39007	6.050	0 1	0.39007	6.050	2 0	−2.54814	−39.521
房地产贷款数	$1-2$ 0	0.22561	4.388	$1-2$ 0	0.22561	4.388	0 1	−0.22430	−4.363
60–89 天逾期	0 0	0.28407	2.940	0 2	0.28407	2.940	1 2	−1.81197	−18.756
家属人数	0	0.15601	1.274	2	−0.24667	−2.014	2	−0.24667	−2.014

原值在上，档位在下。档分显示三位小数，计算使用完整精度。

表 14: 三组人工输入的总分与概率核验

	评分（分）			坏样本概率（%）		
案例	未取整	整数	取整误差	模型输出	原分反算	整数分反算
低风险	644.108	643	−1.108	1.1283	1.1283	1.1720
中风险	586.541	587	+0.459	7.7415	7.7415	7.6287
高风险	474.417	474	−0.417	80.3443	80.3443	80.5713

表 14 对照模型输出与分数反算概率。未取整分数可还原模型概率，展示分取整会带来小幅偏差。原实验在全体 150,000 条记录上核验，最大反算概率误差为 6.11×10^{-16}，逐项求和与 $A - B\eta$ 的最大差为 1.14×10^{-13} 分。测试集最大取整绝对误差为 2.123 分，低于九项各取整的 $9 \times 0.5 = 4.5$ 分理论界。

6 模型评价与风险解释

6.1 评价口径与总体比较

在第 4 节的三种模型冻结后，将 WOE Logistic、原值 Logistic 和常数概率基准应用于同一批 30,000 条测试记录。其中坏样本 2,005 条，好样本 27,995 条，测试坏样本率为 $2{,}005/30{,}000 = 6.6833\%$。以下以坏样本为正类，使用各模型的原始坏样本概率 $\widehat{p}_i$ 评价。常数基准对每条记录均预测训练集坏样本率 6.6844%。

表 15 的 AUC、KS 衡量排序区分度，AP 衡量不同召回水平下的坏样本检出质量，Brier 和对数损失评价逐户概率预测。前三项越大越好，后两项越小越好。在使用同样八个原始字段的两个 Logistic 方案中，WOE 模型的五项指标均优于原值模型。

表 15: 三模型在同一测试集上的表现

模型	AUC	KS	AP	Brier	对数损失
WOE Logistic	0.8487	0.5411	0.3681	0.05073	0.18599
原值 Logistic	0.8252	0.5129	0.3484	0.05226	0.19481
常数概率	0.5000	0.0000	0.0668	0.06237	0.24537

6.2 ROC、PR 与坏样本检出

设 n_1、n_0 分别为坏、好样本数，$\widehat{p}_i^{+}$、$\widehat{p}_j^{-}$ 分别为两类样本的预测坏样本概率。当 $\widehat{p} \geq t$ 时标记，$\mathrm{TP}(t)$、$\mathrm{FP}(t)$ 分别为被标记的坏、好样本数。图 4(a) 的横轴为假阳性率 $\mathrm{FPR}(t) = \mathrm{FP}(t)/n_0$，纵轴为真正率 $\mathrm{TPR}(t) = \mathrm{TP}(t)/n_1$（即坏样本召回率）。每个阈值对应一个坐标点，两轴均以百分比显示。

$$\mathrm{AUC} = \frac{1}{n_1 n_0} \sum_{i=1}^{n_1} \sum_{j=1}^{n_0} \left[\mathbf{1}\{\widehat{p}_i^{+} > \widehat{p}_j^{-}\} + \frac{1}{2}\mathbf{1}\{\widehat{p}_i^{+} = \widehat{p}_j^{-}\} \right],$$

$$\mathrm{KS} = \max_t \{\mathrm{TPR}(t) - \mathrm{FPR}(t)\} = \max_t \left\{ \frac{\mathrm{TP}(t)}{n_1} - \frac{\mathrm{FP}(t)}{n_0} \right\}.$$

其中 $\mathbf{1}\{\cdot\}$ 为指示函数。AUC 按坏样本排在好样本之前计 1、并列计半来汇总所有配对。KS 衡量 ROC 曲线高于随机排序对角线的最大垂直距离。

同一测试集上，依次比较常数基准、原值 Logistic 和 WOE Logistic。

$$\begin{aligned} \mathrm{AUC} \quad & 0.50000000 \xrightarrow{+0.32522162} 0.82522162 \xrightarrow{+0.02348396} 0.84870558, \\ \mathrm{KS} \quad & 0.00000000 \xrightarrow{+0.51292923} 0.51292923 \xrightarrow{+0.02819545} 0.54112468. \end{aligned}$$

箭头标注用原始精度计算的差值。常数基准的预测全部并列，故 AUC 为 0.5、KS 为 0。

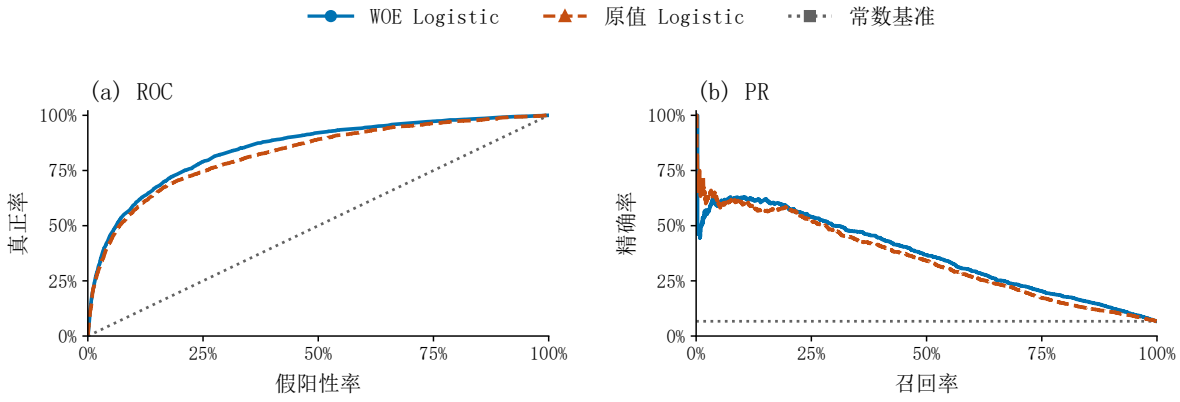


图 4: 三模型的 ROC 与 PR 曲线

图 4(b) 以召回率为横轴，精确率 $\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$ 为纵轴，展示随阈值变化的坏样本覆盖程度与标记对象中坏样本的占比。记阈值由高到低变化时的召回率与精确率为 R_j, P_j，则 $\mathrm{AP} = \sum_j (R_j - R_{j-1}) P_j$，按新增召回量加权，召回量不变的点权重为零。WOE 模型的 AP 为 0.3681，原值模型为 0.3484，常数基准的 AP 等于测试坏样本率 0.0668。WOE 模型的 AP 约为该基准的 5.51 倍。图中的 PR 水平虚线即测试坏样本率。

测试集坏样本仅占 6.68%。常数基准在 $t = 0.5$ 时漏掉全部坏样本（即坏样本召回率为 0 漏掉全部坏样本），准确率仍有 93.32%。沿图 4(b) 的 WOE 曲线从 $t = 0.5$ 下调阈值，召回率由 18.15% 升至 50.02%，检出由 364 条增至 1,003 条，误报由 244 条增至 1,722 条。新增误报多于新增检出，总体准确率由 93.72% 降至 90.92%。精确率（precision）则从 59.87%（364/608）降至 36.81%（1,003/2,725）。

表 16 取两模型召回率首次达到 50% 的曲线点。同样检出 1,003 条坏样本时，WOE 模型少误报 219 条好样本，精确率由原值模型的 34.07% 提高至 36.81%。

表 16: 召回率约 50% 时的坏样本检出对照

模型	检出坏样本	误报好样本	标记总人数	召回率	精确率
WOE Logistic	1,003	1,722	2,725	50.02%	36.81%
原值 Logistic	1,003	1,941	2,944	50.02%	34.07%

下一模块将在验证集上，按误报与漏报代价选择风险标记阈值，按坏样本率上限与最低接受比例选择模拟接受门槛。冻结后再用测试集评价，说明业务目标如何决定复核或接受范围。

6.3 概率损失与校准表现

令 $y_i \in \{0, 1\}$ 为实际标签。Brier 分数度量概率的平方误差，对数损失会加重对自信但错误的预测的惩罚。

$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(\widehat{p}_i - y_i)^2, \qquad \text{LogLoss} = -\frac{1}{n}\sum_{i=1}^{n}\big[y_i \ln \widehat{p}_i + (1 - y_i)\ln(1 - \widehat{p}_i)\big].$$

与原值模型相比，WOE 模型的 Brier 分数由 0.05226 降至 0.05073，对数损失由 0.19481 降至 0.18599，相对下降 2.91% 和 4.53%。常数基准的两项损失均最高。概率损失综合反映逐户预测误差，校准图进一步显示哪些风险组的平均预测偏高或偏低。

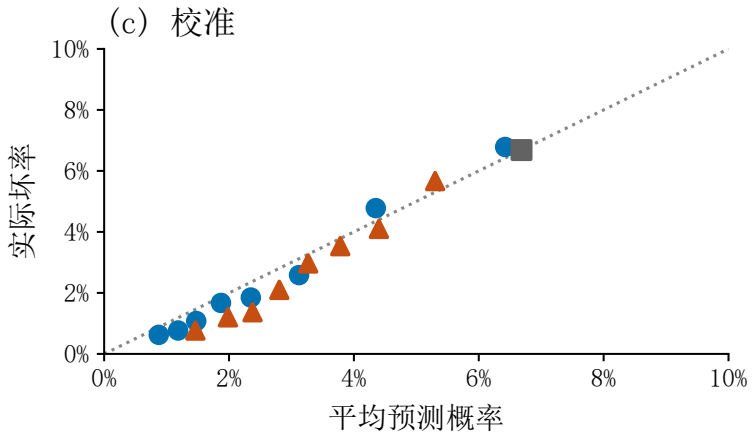


图 5: 三模型的测试集校准图（0–10% 局部放大）

注：蓝色圆点为 WOE Logistic，橙色三角为原值 Logistic，灰色方点为常数基准。

两个 Logistic 模型分别按各自的预测风险降序分为十组，边界取最接近目标十分位的同值块末尾。同一预测值的记录归入同组，故 WOE 各组人数介于 2,968 与 3,040，原

值模型恰好每组 3,000 人。设第 g 组有 n_g 人，比较平均预测概率 $\bar{p}_g$ 与实测坏率 $\bar{y}_g$。图 5 的对角线表示两者相等，点在线上方表示该组风险被低估。测试集中，WOE 和原值 Logistic 的逐户预测概率不超过 10% 的比例分别为 85.77% 和 87.87%，因此图中两轴均放大至 0–10%。两个模型各有八组的平均预测概率和实际坏率同时落在该区间。表 17 列出每组人数和偏差，两模型的同序号组各自按预测风险划分。

表 17: 两个 Logistic 模型的分组校准明细

	WOE Logistic				原值 Logistic			
组	人数	平均预测	实际坏率	差值	人数	平均预测	实际坏率	差值
1	3,001	34.50%	35.25%	+0.75	3,000	32.48%	33.80%	+1.32
2	3,010	10.07%	11.43%	+1.36	3,000	8.33%	11.33%	+3.01
3	2,992	6.42%	6.78%	+0.36	3,000	5.30%	5.67%	+0.37
4	2,992	4.35%	4.78%	+0.43	3,000	4.40%	4.10%	−0.30
5	2,980	3.12%	2.58%	−0.54	3,000	3.78%	3.53%	−0.25
6	3,029	2.35%	1.85%	−0.50	3,000	3.27%	2.97%	−0.30
7	2,992	1.87%	1.67%	−0.20	3,000	2.81%	2.10%	−0.71
8	2,968	1.47%	1.08%	−0.40	3,000	2.38%	1.37%	−1.01
9	2,996	1.19%	0.77%	−0.42	3,000	1.98%	1.20%	−0.78
10	3,040	0.88%	0.62%	−0.25	3,000	1.46%	0.77%	−0.70

注：差值为实际坏率减平均预测概率，单位为百分点。常数基准单列一组，共 30,000 人，平均预测为 6.6844%，实际坏率为 6.6833%。

WOE 模型前四组的平均预测低于实际坏率，后六组则偏高。偏差最明显的是第 2 组，预测为 10.07%，实际为 11.43%。原值模型同序号组的预测为 8.33%，实际为 11.33%。按人数加权的绝对组差 $\sum_g (n_g/n)|\bar{y}_g - \bar{p}_g|$ 在 WOE 模型为 0.52%，在原值模型为 0.87%。这一统计量依赖分组方式。

6.4 WOE 评分的风险分层

按式 (10)，未取整总分越低，预测坏样本概率越高。将测试记录按未取整分数升序排列，沿用上述近似等频方法划分十组，保留每个同分块的完整性。第 1 组是最低分、最高风险组。表 18 列出各组观测分数范围、人数、坏样本数、平均预测和实际坏率。第 g 组的累计覆盖率为前 g 组坏样本数之和除以全部 2,005 条坏样本。

表 18: WOE 评分的十组风险分层

组	观测分数范围	人数	坏样本	平均预测	实际坏率	累计覆盖
1	434.095–566.542	3,001	1,058	34.50%	35.25%	52.77%
2	566.579–585.813	3,010	344	10.07%	11.43%	69.93%
3	585.815–598.843	2,992	203	6.42%	6.78%	80.05%
4	598.849–610.015	2,992	143	4.35%	4.78%	87.18%
5	610.102–618.179	2,980	77	3.12%	2.58%	91.02%
6	618.193–626.538	3,029	56	2.35%	1.85%	93.82%
7	626.591–632.496	2,992	50	1.87%	1.67%	96.31%
8	632.615–639.667	2,968	32	1.47%	1.08%	97.91%
9	639.830–647.650	2,996	23	1.19%	0.77%	99.05%
10	647.982–663.133	3,040	19	0.88%	0.62%	100.00%

注：分数范围为本组样本的实际最小值至最大值，按三位小数展示。组别由高风险排至低风险。

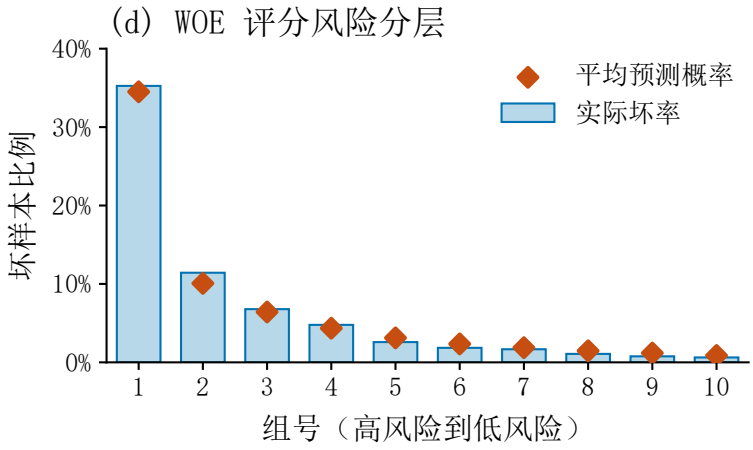


图 6: WOE 评分各组的平均预测与实际坏率

图 6 显示，实际坏率随分数提高逐组下降。第 1 组坏率为 35.25%，约为总体坏率的 5.28 倍。第 2 组降至 11.43%，第 3 组为 6.78%，接近总体水平。最低风险组 3,040 人中有 19 条坏样本，坏率为 0.625%。这一结果表明评分在测试集中形成了可观察的风险梯度。

按风险从高到低检查客户时，先覆盖第 1 组约 10.00% 的记录，就能覆盖 1,058 条坏样本，占全部坏样本的 52.77%。覆盖前两组约 20.04% 的记录时，累计覆盖率提高到 69.93%。再纳入第 3 组，覆盖 9,003 人（30.01%）和 1,605 条坏样本（80.05%）。边际检出率随检查范围扩大而降低，例如第 3 组每百人约检出 7 条坏样本，低于第 1 组的约 35 条。这些比例描述测试集上的风险集中程度，供后续分析处理容量与检出量的取舍。

7 阈值选择与业务决策

本节用冻结的 WOE Logistic 概率和未取整评分，在验证集选定规则后，以同一批 30,000 条测试记录评价。误报和漏报成本、审批坏率目标均为教学情景设定。

7.1 代价敏感的风险标记

设客户的坏样本概率为 p。标记好客户产生误报成本 $C_{\mathrm{FP}}=1$，放过坏客户产生漏报成本 $C_{\mathrm{FN}}=5$。在概率可信且成本适用于每位客户时，标记的条件期望成本为 $1-p$，放过的条件期望成本为 $5p$。取等号时标记，得到

$$1-p\le 5p \quad\Longleftrightarrow\quad p\ge t_{\mathrm{theory}}=\frac{1}{1+5}=\frac{1}{6}.$$

以冻结模型的预测概率 $\widehat{p}$ 执行时，由式 (10) 得到等价分数规则

$$\widehat{p}\ge t \quad\Longleftrightarrow\quad S\le s(t),\qquad s(t)=A+B\ln\frac{1-t}{t}.$$

验证前固定概率网格 $0.01,0.02,\ldots,0.99$，另纳入 $1/6$。以 $(\mathrm{FP}+5\,\mathrm{FN})/n$ 最小为准，同成本时取较高阈值以减少标记量。验证集最优阈值为 0.13，均成本为 0.21060，对应 $S\le 569.891525\ldots$。同一验证集上，0.5 和 1/6 的均成本分别为 0.28133 和 0.21730。冻结 0.13 后，按表 19 在测试集比较三种规则。

表 19: 三种风险标记规则的测试集比较

规则	分数上限	TN	FP	FN	TP	标记率	召回率	精确率	均成本
基准 0.5	515.041	27,751	244	1,641	364	2.03%	18.15%	59.87%	0.28163
理论 1/6	561.480	26,434	1,561	1,041	964	8.42%	48.08%	38.18%	0.22553
验证 0.13	569.892	25,830	2,165	905	1,100	10.88%	54.86%	33.69%	0.22300

表 20 按实际类别展开三种规则的混淆矩阵。坏样本为正类，好样本行中的标记人数为误报（FP），坏样本行中的未标记人数为漏报（FN）。

表 20: 三种风险标记规则的测试集混淆矩阵

	基准 $t=0.5$		理论 $t=1/6$		验证选定 $t=0.13$	
实际类别	未标记	标记	未标记	标记	未标记	标记
好样本	27,751	244	26,434	1,561	25,830	2,165
坏样本	1,641	364	1,041	964	905	1,100

0.5 只标记 608 户，精确率为 59.87%，但漏掉 1,641 条坏样本，均成本最高。由 1/6 降至 0.13 后，标记量由 2,525 户增至 3,265 户，少漏 136 条坏样本，多误报 604 户。少漏带来的成本节省为 $136\times 5=680$，扣除新增误报成本后净省 76，均成本由 0.22553 降至 0.22300。验证阈值在三种规则中成本最低，同时需要处理测试集约 10.88% 的客户，精确率降至 33.69%。

7.2 坏率约束下的模拟审批

给定整数分数门槛 c，接受所有未取整评分 $S_i \geq c$ 的客户，同分者使用同一规则。设验证集接受人数为 N_c、其中坏样本数为 D_c、验证集总人数为 n_{val}。在事先固定的 $c = 300, 301, \ldots, 900$ 上求

$$\max_{c} \frac{N_c}{n_{\text{val}}} \qquad \text{满足} \qquad \frac{D_c}{N_c} \leq 5\%, \qquad \frac{N_c}{n_{\text{val}}} \geq 10\%.$$

同接受人数时取较高门槛，若无可行门槛则报告不可行。验证集在 530 分时接受 28,973 户，坏率为 5.03%，超出约束。遍历网格后，531 分是可行门槛中接受人数最多的方案，接受 28,928 户，坏率为 4.97%。测试阶段沿用这一门槛，结果见表 21。

表 21: 冻结审批门槛在验证集与测试集上的表现

样本	门槛	接受人数	接受率	坏样本	平均预测	实际坏率	95% 区间
验证集	531	28,928	96.43%	1,437	4.72%	4.97%	–
测试集	531	28,974	96.58%	1,465	4.79%	5.06%	[4.81%, 5.31%]

区间为测试集接受样本实际坏率的记录层面 Wilson 95% 二项比例区间。

测试集接受率为 96.58%，接受者平均预测为 4.79%，实际坏率为 5.06%。点估计超过 5% 目标约 0.06 个百分点，区间 [4.81%, 5.31%] 跨越 5%。据此记录测试点估计超标，保留冻结门槛 531 分。区间表明，接受者坏率在 5% 附近仍有抽样不确定性。

按本报告的评分刻度，600 分对应好坏几率 19 : 1，预测坏样本概率为 $1/(19+1) = 5\%$。对一位恰好得 600 分的客户，这表示模型根据评分时已知的信息，估计其未来两年内发生严重逾期或更严重情形的概率为 5%。若规定 $S \geq 600$ 时接受，每位接受者的预测概率都不超过 5%，客群的平均预测概率也不超过 5%。实际坏样本率则要等两年表现窗口结束后，用发生目标事件的人数除以接受人数计算。受模型校准偏差和样本波动影响，实际坏样本率可能超过 5%。本方案约束的是验证集的客群实际坏样本率，因此允许部分预测概率高于 5% 的客户被接受。

两种规则的行动目标 风险标记用于安排复核，在给定误报和漏报代价下比较标记量、检出量与成本。模拟审批则在客群坏率约束下扩大接受范围。例如，未取整分数在 531 到 569.891525... 之间的客户，可同时满足接受与风险标记条件。现有数据支持比较复核容量和模拟接受风险。若要评价实际授信收益或优化审批政策，还需结合贷款收益、违约损失率与拒绝样本的后续表现。

8 选做拓展：评分分布的 PSI

冻结分数档 以 90,000 条训练记录的 WOE 未取整总分为基准，在完整同分块之间选择最接近训练十分位的位置切分。每档右端取该档训练样本的最大分数，等于切点的记录归较低一档，两端使用开口区间。切点保存后，将同一套分档原样应用于 30,000 条测试记录。

计算口径 令 p_k 和 q_k 分别为训练集和测试集落入第 k 档的比例，评分分布的群体稳定性指标为

$$\mathrm{PSI} = \sum_{k=1}^{K} (q_k - p_k) \ln \frac{q_k}{p_k}.$$

若任一档在任一子集中人数为零，则两个子集的每一档均加 0.5，再分别以各自总人数加 $0.5K$ 归一化，避免零比例进入对数。表 22 中每档均有记录，本次直接使用实际占比。

表 22: 训练集与测试集的固定分数档占比及 PSI

档	未取整分数范围	训练人数	训练比例	测试人数	测试比例	PSI 分项
1	$(-\infty, 565.795]$	8,999	10.00%	2,956	9.85%	0.000021
2	$(565.795, 584.817]$	8,992	9.99%	2,922	9.74%	0.000064
3	$(584.817, 598.843]$	9,065	10.07%	3,125	10.42%	0.000116
4	$(598.843, 610.102]$	8,996	10.00%	3,033	10.11%	0.000013
5	$(610.102, 618.406]$	8,964	9.96%	3,044	10.15%	0.000035
6	$(618.406, 626.591]$	8,985	9.98%	2,926	9.75%	0.000054
7	$(626.591, 633.237]$	8,984	9.98%	3,070	10.23%	0.000062
8	$(633.237, 639.830]$	9,204	10.23%	3,065	10.22%	0.000000
9	$(639.830, 647.650]$	8,657	9.62%	2,819	9.40%	0.000052
10	$(647.650, +\infty)$	9,154	10.17%	3,040	10.13%	0.000001
	合计	90,000	100.00%	30,000	100.00%	0.000418

切点按三位小数展示，分档使用完整精度。PSI 合计按未舍入的各档分项求和。

结果解释 总 PSI 为 0.000418。贡献最大的第 3 档，训练和测试占比分别为 10.07% 和 10.42%，按原始比例计算相差约 0.34% 。整体来看，两个随机子集在固定分数档上的分布接近。由于样本来自同一数据集的分层随机划分，这一比较反映的是随机留出样本之间的分布差异。检验跨期稳定性需要按评分日期获取后续客群，并沿用同一模型和固定分数档作比较。

A 模块与 Python 复现文件

表 23 按报告模块列出运行入口。脚本沿用项目目录结构，在仓库根目录运行 `pythonrun_pipeline.py` 可复现数值结果。表中列出各阶段的独立入口。

表 23: 报告模块与 Python 文件对照

开发环节	对应文件
模块一　样本划分与重复检查	`scripts/split_samples.py`
模块二　审计、风险分析与清洗	`scripts/audit_data.py`、`scripts/feature_risk.py` `scripts/preprocess.py`
模块三　分箱、WOE 与 IV	`scripts/binning_woe.py`
模块四　Logistic 与基准比较	`scripts/fit_logistic.py`
模块五　评分卡与逐户核验	`scripts/scorecard.py`
模块六　模型评价与风险分层	`scripts/evaluate_models.py`
模块七　阈值选择与业务决策	`scripts/decision_thresholds.py`
选做拓展　评分分布 PSI	`scripts/score_psi.py`
公共依赖　绘图与检查	`utils/setup_style.py`、`utils/plot_style.py` `utils/export_figure.py`、`utils/visual_qa.py`

输入与运行顺序　将 Kaggle 原始 `cs-training.csv` 与 `Data Dictionary.xls` 放在项目根目录。样本划分种子为 `20261103`。模块七先用参数 `freeze` 在验证集上冻结阈值，再用 `evaluate` 评价测试集。程序将结果写入 `results/`，图形写入 `figures/`。

Python 环境　Python 3.12。主要依赖为 NumPy 2.3.4、pandas 2.3.3、SciPy 1.16.2、scikit-learn 1.7.2、Matplotlib 3.10.7、Pillow 12.0.0、PyMuPDF 1.28.2、xlrd 2.0.2。